САНКТ-ПЕТЕРБУРГСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

Дисциплина: Инженерия данных
Отчет
Лабораторная работа №3

Выполнила:
Долбенко Олеся
ИСУ: 465781
Группа: J3313

Санкт-Петербург
2026 г.

1. Цель и задачи работы

Цель: Закрепление навыков работы с объектными хранилищами и распределенными вычислениями, а также проведение сравнительного анализа производительности различных подходов к обработке данных.

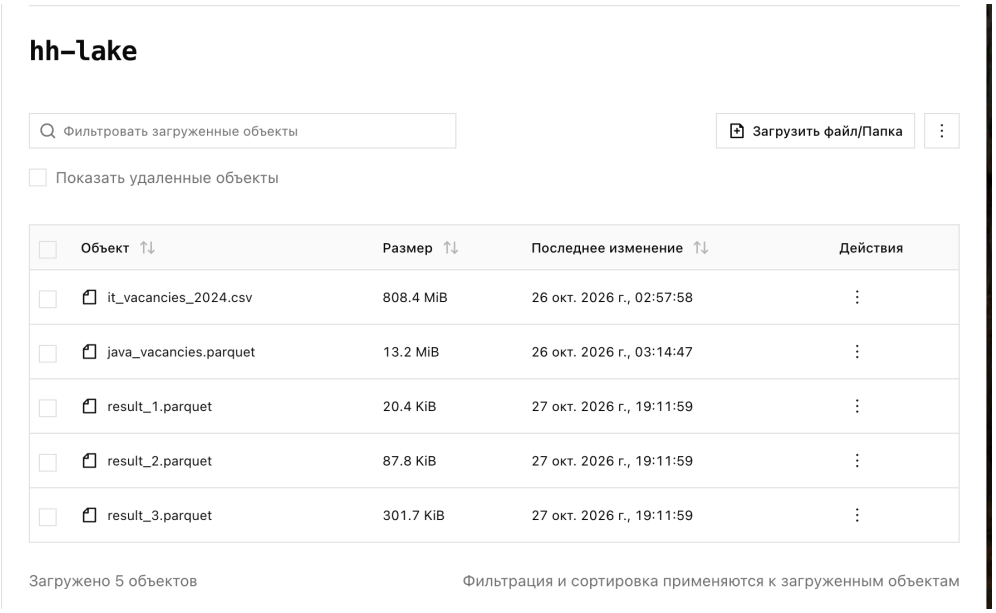
Задачи:

1. Развернуть локальное объектное хранилище RustFS.
2. Загрузить датасет IT-вакансий и отфильтровать вакансии для Java-разработчиков.
3. Реализовать собственный алгоритм MapReduce (с чтением чанками) и SQL-запросы в DuckDB для подсчета частот одиночных навыков, пар и троек.
4. Провести верификацию (сверить результаты обоих способов).
5. Проанализировать влияние навыков на медианную заработную плату.
6. Провести региональный анализ.
7. Оценить ресурсоемкость (профилирование) собственного MapReduce.

2. Ход работы

2.1. Развёртывание хранилища и загрузка данных

С помощью Docker было развернуто S3-совместимое хранилище RustFS. В нем был создан баке hh-lake
Исходный датасет был загружен в хранилище. Для оптимизации работы он был сконвертирован в формат .parquet, что позволило сократить размер файла до 13 МБ и ускорить чтение.



2.2 Подсчёт навыков двумя способами

Для фильтрации вакансий использовалось условие: в названии вакансии есть «java», но нет «javascript» (чтобы исключить фронтенд-разработчиков).

1. DuckDB: Был написан SQL-запрос, обращающийся напрямую к S3. Запрос разбивал массив навыков и агрегировал их с помощью count.
2. MapReduce: Скрипт читает Parquet-файл из хранилища чанками по 50 000 строк (не загружая весь файл в память). В цикле по чанкам выполняются фазы Map и Reduce с использованием collections.Counter Результаты сохраняются обратно в S3 в виде трех файлов (result_1, result_2, result_3).

```
(base) olesiadolbenko@Noutbuk-Olesia Desktop % python3 mapreduce.py
Результаты MapReduce сохранены в S3 (result_1, result_2, result_3)
(base) olesiadolbenko@Noutbuk-Olesia Desktop %
```

2.3. Верификация результатов

Была проведена сверка контрольных чисел (самый частый навык), полученных обоими способами.
Как показал запуск скрипта verify.py, результаты совпали:

- MapReduce: 4484 вхождений (навык Java).
- DuckDB: 4484 вхождений (навык Java).

```
(base) olesiadolbenko@Noutbuk-Olesia Desktop % python3 verify.py
MapReduce: 4484 вхождений (навык: Java)
DuckDB:    4484 вхождений (навык: Java)
Верификация пройдена, результаты совпадают
(base) olesiadolbenko@Noutbuk-Olesia Desktop %
```

2.4. Анализ влияния навыков на зарплату

Для расчета использовалась медианная зарплата (salary_from). Базовая медиана по всем Java-вакансиям 150 000 руб.
analytics.py выявил:

- Повышают зарплату: Пары Kafka + Kubernetes и PostgresSQL + Redis дают медиану 230 000 руб. (прибавка более 53%). Тк рынок высоко ценит разработчиков, умеющих строить распределенные системы и работать с высоконагруженными БД.
- Понижают зарплату: Пары SVN + Unit Testing, SVN + ООП дают медиану 70 000 руб. (падение более чем в 2 раза). Использование устаревшей системы контроля версий (SVN) и фокус на базовых тестах характерны для легаси-проектов и низкооплачиваемых позиций (Junior).

```
(base) olesiadolbenko@Noutbuk-Olesia Desktop % python3 analytics.py
Базовая медианная зарплата (Java): 150,000 руб.

 Пары навыков (Наибольшая медианная зарплата)
('Kafka', 'Kubernetes'): 230,000 руб. (встреч: 37)
('PostgreSQL', 'Redis'): 230,000 руб. (встреч: 30)
('Kafka', 'SQL'): 220,000 руб. (встреч: 43)
('Kubernetes', 'PostgreSQL'): 220,000 руб. (встреч: 51)
('Kubernetes', 'Spring Boot'): 220,000 руб. (встреч: 32)

 Пары навыков (Наименьшая медианная зарплата)
('Unit Testing', 'ООП'): 70,000 руб. (встреч: 51)
('Spring Framework', 'Unit Testing'): 70,000 руб. (встреч: 67)
('SVN', 'ООП'): 70,000 руб. (встреч: 52)
('SVN', 'Unit Testing'): 70,000 руб. (встреч: 46)
('SVN', 'Spring Framework'): 70,000 руб. (встреч: 53)

 Тройки навыков (Наибольшая медианная зарплата)
('Java', 'Kafka', 'Kubernetes'): 230,000 руб. (встреч: 34)
('Apache Kafka', 'Java', 'PostgreSQL'): 225,000 руб. (встреч: 30)
('Docker', 'Kubernetes', 'PostgreSQL'): 220,000 руб. (встреч: 33)
('Java', 'Kubernetes', 'PostgreSQL'): 220,000 руб. (встреч: 47)
('Kafka', 'Kubernetes', 'PostgreSQL'): 220,000 руб. (встреч: 31)

 Тройки навыков (Наименьшая медианная зарплата)
('Spring Framework', 'Unit Testing', 'ООП'): 70,000 руб. (встреч: 51)
('SVN', 'Unit Testing', 'ООП'): 70,000 руб. (встреч: 46)
('SVN', 'Spring Framework', 'ООП'): 70,000 руб. (встреч: 52)
('SVN', 'Spring Framework', 'Unit Testing'): 70,000 руб. (встреч: 46)
('PostgreSQL', 'Unit Testing', 'ООП'): 70,000 руб. (встреч: 50)

 Сравнительный анализ по регионам
          area  vacancies  median_salary
        Москва        468       200000.0
Санкт-Петербург        157       150000.0
    Новосибирск         64       150000.0

 Топ 3 навыка в каждом регионе

Регион: Москва
     clean_skill  cnt
            Java  326
Spring Framework  159
      PostgreSQL  128

Регион: Санкт-Петербург
     clean_skill  cnt
            Java  111
Spring Framework   77
      PostgreSQL   56

Регион: Новосибирск
     clean_skill  cnt
            Java   53
      PostgreSQL   29
Spring Framework   24
(base) olesiadolbenko@Noutbuk-Olesia Desktop %
```

2.5. Региональный анализ

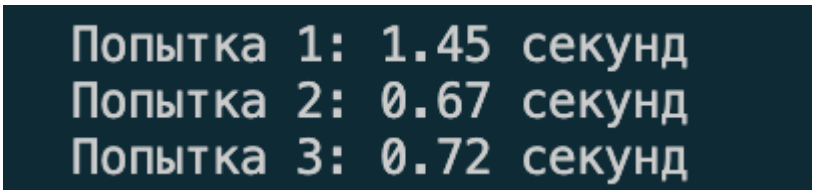
Были выбраны три региона с наибольшим числом вакансий. Результаты:

- Москва: 468 вакансий, медианная зарплата 200 000 руб.
- Санкт-Петербург: 157 вакансий, медианная зарплата 150 000 руб.
- Новосибирск: 64 вакансии, медианная зарплата 150 000 руб.
  Москва лидирует как по объему рынка, так и по уровню оплаты (на 33% выше, чем в Спб). При этом топ-3 навыка везде одинаков (Java, Spring Framework, PostgreSQL), что говорит о единых стандартах стека.

2.6. Профилирование нагрузки

Для оценки производительности собственного MapReduce было проведено 3 замера времени выполнения.

- Попытка 1: 1.45 сек
- Попытка 2: 0.67 сек
- Попытка 3: 0.72 сек
  Среднее время: 2.16 сек
  Потребление памяти: ~150-200 МБ. Благодаря чанковому чтению , программа не загружает 800 МБ в оперативную память целиком, что делает ее безопасной для слабых машин. DuckDB выполняет аналогичный запрос быстрее за счет векторных вычислений, но собственный MapReduce показал достойную скорость при минимальных требованиях к RAM.



3. Вывод

В ходе лабораторной работы был успешно развернут стек для работы с большими данными (RustFS + Python + DuckDB). Я научились работать с S3-хранилищем, оптимизировать данные (Parquet) и писать собственный MapReduce, который читает данные чанками. Числа, полученные независимыми способами (MapReduce и SQL), полностью совпали, что подтверждает корректность вычислений. Анализ данных выявил явные бизнес-тренденции: наибольшую ценность на рынке представляют навыки работы с высоконагруженными системами (Kafka, Kubernetes), а регионом с наивысшей оплатой труда остается Москва.